

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК**

Кузнецов Егор Сергеевич

МАГИСТЕРСКАЯ ДИССЕРТАЦИЯ

**Распознавание показаний круглых аналоговых шкал на изображениях
Recognition of Circular Analog Gauge Readings in Images**

по направлению подготовки 01.04.02 Прикладная математика и информатика
образовательная программа «Искусственный интеллект»

Студент
Е. С. Кузнецов

Научный руководитель
доцент
И. А. Макаров

Москва 2026

Содержание

Аннотация	3
Ключевые слова	4
1 Введение	5
2 Теоретическая часть	8
2.1 Специфика задачи считывания показаний аналоговых датчиков . . .	8
2.2 Основные подходы к решению задачи	9
2.3 Сегментация стрелки как промежуточное представление	9
2.4 Синтетические данные и доменная рандомизация	11
2.5 Метрики качества и их смысл	11
2.6 Сравнение трех постановок задачи	12
2.7 Вывод по теоретической части	13
3 Практическая часть	14
3.1 Общая постановка практической части	14
3.2 Подготовка данных	14
3.3 Эксперимент 1. Двухэтапный пайплайн: детекция и ключевые точки	15
3.4 Эксперимент 2. Сегментация стрелки	17
3.5 Алгоритм получения угла стрелки и показания	19
3.6 Эксперимент 3. Прямая регрессия показания	20
3.7 Тест на реальных данных	21
3.8 Сравнительный анализ результатов	23
3.9 Ограничения текущей реализации и план доработки	24
3.10 Вывод по практической части	25
Список литературы	26

Аннотация

В работе рассматривается задача автоматического считывания показаний аналоговых стрелочных датчиков по изображениям. Тема актуальна для промышленного мониторинга, поскольку аналоговые приборы продолжают использоваться на реальных объектах, а ручной съем показаний требует времени и подвержен ошибкам. Отдельное значение эта задача имеет для небольших производств, где полная замена измерительной инфраструктуры на цифровые датчики часто экономически или организационно невозможна. В таких условиях компьютерное зрение может выступать как промежуточный слой цифровизации: камера считывает уже установленный прибор, не требуя остановки производственной линии и изменения технологической цепочки.

Практическая часть опирается на синтетический датасет SynthGauge и сравнивает несколько подходов: интерпретируемый пайплайн детекции циферблата с последующим восстановлением геометрии шкалы, сегментацию стрелки как способ более устойчивого определения ее направления и прямую регрессию показаний. Эксперименты показывают, что локализация циферблата на синтетических данных уже решается надежно, тогда как основная сложность связана с восстановлением геометрии стрелки и переносом решения на реальные фотографии. Прямая регрессия дает наиболее сильный численный результат на синтетическом тесте, но хуже объясняет природу ошибки. Геометрический пайплайн с сегментацией стрелки выглядит более интерпретируемым и перспективным для промышленной диагностики, хотя пока не достигает стабильности, достаточной для полностью автономного применения на реальных данных.

Ключевые слова

аналоговые датчики, компьютерное зрение, считывание показаний, синтетические данные, детекция объектов, ключевые точки, сегментация стрелки, ре-

грессия

1. Введение

Автоматическое считывание показаний аналоговых стрелочных приборов остается актуальной задачей для промышленности, энергетики, транспорта и систем технического мониторинга. Несмотря на распространение цифровых датчиков, на реальных объектах по-прежнему используется большое число аналоговых манометров, амперметров, вольтметров и других приборов, показания которых часто снимаются вручную. Это делает задачу автоматического распознавания практической и исследовательской одновременно [1, 2, 3, 4].

Особенно заметна эта проблема на малых и средних производствах. Для крупного предприятия цифровизация измерительной инфраструктуры может быть частью долгосрочной программы модернизации: датчики заменяются на цифровые, данные поступают в SCADA или MES-системы, а технологические процессы постепенно перестраиваются под новые каналы мониторинга. Для небольшого завода такой путь часто оказывается слишком дорогим. Стоимость самих датчиков является только одной частью затрат: дополнительно нужны монтаж, остановка оборудования, перенастройка автоматики, проверка совместимости с существующими контроллерами, обучение персонала и последующее обслуживание.

Поэтому на практике большое количество исправных аналоговых приборов продолжает использоваться даже тогда, когда руководству предприятия уже нужны цифровые журналы, контроль отклонений и удаленный мониторинг. Компьютерное зрение в таком сценарии не заменяет промышленную автоматизацию полностью, но позволяет сделать более мягкий переход. Камера может быть установлена перед существующим прибором, а алгоритм считывания будет переводить визуальное показание в числовое значение. Такое решение не требует вмешательства в измерительный контур, не меняет сертифицированную часть оборудования и может внедряться постепенно: сначала для контроля отдельных узких мест, затем для расширения мониторинга на другие участки.

Со стороны компьютерного зрения эта задача сложнее обычной классификации. Необходимо найти прибор в кадре, определить положение стрелки относительно шкалы и перевести геометрию изображения в числовое значение. Дополнительные трудности создают блики, загрязнения, искажение перспективы и разнообразие конструкций приборов [3, 5, 4, 6, 7].

Еще одна проблема связана с нехваткой публичных размеченных данных. Для таких систем важную роль играют синтетические датасеты и доменная рандомизация, позволяющие получать большие объемы автоматически размеченных изображений и воспроизводимо сравнивать модели [8, 9, 10, 11, 12, 13].

В данной работе поиск оптимального решения осуществляется на датасете SynthGauge. В практической части сравниваются два семейства подходов: интерпретируемый геометрический пайплайн, в котором детекция циферблата, локализация ключевых точек и сегментация стрелки образуют единый контур считывания, и прямая регрессия нормализованного показания [3, 8, 4, 7, 14].

Целью работы является анализ и сравнение методов автоматического считывания показаний аналоговых стрелочных датчиков по изображениям на основе синтетических данных и единого экспериментального контура.

Для достижения поставленной цели формулируются следующие задачи:

1. Проанализировать специфику задачи считывания показаний аналоговых приборов и основные трудности ее автоматизации.
2. Рассмотреть существующие подходы: геометрические методы, локализацию ключевых точек, сегментацию стрелки и прямую регрессию.
3. Описать экспериментальный контур на базе датасета SynthGauge и используемые метрики качества.
4. Описать алгоритм восстановления угла стрелки и перевода угловой геометрии в нормализованное показание.
5. Сравнить интерпретируемый пайплайн, прямую регрессию и проверку на

реальных изображениях, определить ограничения текущего решения и направления его развития.

Объектом исследования являются изображения аналоговых стрелочных приборов промышленного типа.

Предмет исследования составляют методы компьютерного зрения и машинного обучения, применяемые для локализации прибора, оценки геометрии стрелки и шкалы, а также для прямого предсказания отображаемого числового значения.

Научная новизна работы в предлагаемой постановке состоит не столько в создании еще одной отдельной модели, сколько в систематическом сопоставлении различных формализаций одной и той же прикладной задачи на едином наборе синтетических данных с общей схемой аннотаций. Такой подход позволяет более четко понять, в каком месте задачи возникает основная ошибка: на этапе обнаружения прибора, на этапе восстановления его геометрии или на этапе прямого вычисления показания.

Практическая значимость работы связана с возможностью использования разработанного пайплайна как основы для систем дистанционного промышленного мониторинга. Для малых предприятий такой подход особенно полезен как вариант постепенной цифровизации: вместо немедленной замены всей приборной базы можно добавить визуальный слой контроля поверх уже установленного оборудования. Полученные результаты могут быть использованы при проектировании сервисов автоматической инспекции оборудования, а также как база для дальнейшего перехода от синтетического домена к реальным производственным изображениям.

В данной работе сначала рассматриваются существующие подходы, синтетические данные и метрики оценки, затем описываются данные, эксперименты и анализ результатов.

2. Теоретическая часть

2.1. Специфика задачи считывания показаний аналоговых датчиков

Задача считывания показаний аналогового стрелочного прибора по изображению требует одновременно решать три подзадачи: локализовать объект, восстановить геометрию шкалы и стрелки и перевести эту геометрию в число. В отличие от обычной классификации, здесь важна не только принадлежность изображения к классу, но и точное взаимное расположение визуальных элементов [3, 5, 4, 6].

Сложность усиливается из-за высокой вариативности приборов и условий съемки. На результат влияют форма корпуса, тип шкалы, материал стекла, блики, загрязнения, перспектива и частичное перекрытие. Поэтому даже небольшая ошибка в положении стрелки может приводить к заметной ошибке итогового показания [15, 2, 6, 7].

С прикладной точки зрения важна не только точность алгоритма, но и способ его внедрения. На малом производстве измерительные приборы часто являются частью давно отлаженного процесса. Замена манометра или амперметра на цифровой датчик может затронуть не только сам прибор, но и трубопровод, электрическую обвязку, шкаф автоматики, регламент обслуживания и документацию. Даже если отдельный цифровой датчик стоит недорого, суммарная стоимость перехода складывается из остановки линии, работ по интеграции и риска нарушить стабильный технологический процесс. Поэтому решения, которые работают поверх существующей инфраструктуры, имеют самостоятельную ценность.

Визуальное считывание аналоговых приборов относится именно к такому классу решений. Оно не требует механического подключения к измерительному контуру и может быть развернуто поэтапно: сначала оператор получает подсказку или автоматический журнал, затем система начинает сигнализировать об отклонениях, и только после накопления доверия может использоваться в более строгих

сценариях контроля. Это делает задачу важной не только для исследовательских бенчмарков, но и для реальных предприятий, где цифровизация должна учитывать бюджетные ограничения и необходимость непрерывной работы оборудования.

2.2. Основные подходы к решению задачи

Исторически задачи считывания стрелочных приборов решались геометрическими и эвристическими методами: через поиск окружности циферблата, выделение стрелки, оценку угла и перевод этого угла в показание. Для этого применялись преобразование Хафа, анализ контуров, бинаризация и морфологические операции. Такие методы интерпретируемы, но чувствительны к качеству изображения и отклонениям реальной геометрии от ожидаемой модели [16, 17, 15, 6, 18].

Современные подходы чаще опираются на глубокое обучение. В рамках данной работы важны три практические схемы. Первая схема является интерпретируемой: прибор сначала детектируется на изображении, а затем по ключевым точкам восстанавливаются центр шкалы и ее границы. Вторая схема дополняет этот контур сегментацией стрелки, то есть модель выделяет не одну точку, а всю область указателя. Третья схема сразу предсказывает показание по изображению циферблата и тем самым упрощает контур, но делает его менее прозрачным для анализа ошибок [19, 3, 4, 8, 14, 7].

2.3. Сегментация стрелки как промежуточное представление

Ключевые точки удобны как компактное описание геометрии: достаточно знать центр шкалы, начало и конец основной дуги, а также положение кончика стрелки. Однако для стрелки такая постановка оказывается довольно хрупкой. Кончик может быть тонким, частично сливаться со шкалой, перекрываться бликом или попадать на темный участок циферблата. Если модель ошибается всего на несколько пикселей, ошибка угла может оказаться существенной, особенно для

приборов с короткой стрелкой или малым радиусом шкалы.

Сегментация стрелки решает задачу иначе. Модель должна выделить все пиксели, принадлежащие указателю, после чего направление стрелки можно восстановить геометрически. Такая постановка использует больше визуальной информации: учитывается не только самый дальний конец, но и форма всей стрелки, ее длина, ширина и положение относительно центра. В задачах промышленного зрения это особенно важно, поскольку реальная стрелка может иметь нестандартную форму: тонкую линию, клиновидный указатель, широкое основание или декоративный противовес.

С точки зрения архитектуры сегментация может быть реализована разными способами: через специализированные сети семантической сегментации, такие как U-Net и DeepLab, через instance segmentation, например Mask R-CNN, или через современные YOLO-seg модели [20, 21, 22, 23]. В данной работе используется именно прикладная логика YOLO-seg: на вход подается crop циферблата, а на выходе ожидается маска класса «стрелка». Такой подход хорошо согласуется с остальными этапами проекта, потому что детекция, keypoints и сегментация остаются внутри одного семейства моделей и могут обучаться в едином экспериментальном контуре.

Важно, что сегментация не отменяет необходимость ключевых точек. Для перевода маски стрелки в численное значение все равно нужны центр шкалы и две опорные точки основной дуги. Поэтому в итоговом геометрическом пайплайне задачи распределяются следующим образом: детектор отвечает за локализацию прибора, модель ключевых точек задает систему координат шкалы, а сегментация отвечает за направление стрелки. Такая декомпозиция делает ошибку более объяснимой: если неверно найден прибор, проблема возникает на первом этапе; если неверно восстановлена дуга шкалы, виноват этап keypoints; если маска стрелки захватила лишние элементы, ошибка относится к сегментации.

2.4. Синтетические данные и доменная рандомизация

Одним из главных препятствий для обучения таких систем является нехватка реальных размеченных данных. Синтетические датасеты частично снимают эту проблему, поскольку позволяют автоматически получать точные аннотации и варьировать освещение, материалы, ракурс и состояние поверхности [9, 10, 11, 8].

Ключевую роль при этом играет доменная рандомизация: модель обучается на большом числе искусственно разнообразных сцен и за счет этого меньше привязывается к узкому набору визуальных признаков [9, 10, 12].

В проекте используется датасет SynthGauge — набор из 9000 синтетических изображений круглых аналоговых датчиков с единым набором аннотаций для нескольких задач. Он содержит bounding box, четыре ключевые точки и нормализованное показание. Помимо этого, в разметке так же присутствуют такие данные, как показание стрелки, значение начала и конца, что позволит в дальнейшем сразу конвертировать нормализованное показание в абсолютное и тем самым замерять качество работы пайплайна в промышленных условиях. [8, 24].

2.5. Метрики качества и их смысл

Для детекции приборов стандартно используются метрики *precision*, *recall*, *mAP@0.5* и *mAP@0.5 : 0.95*. Они позволяют оценить, насколько хорошо модель находит прибор и насколько точно совпадает предсказанная область с разметкой. Для рассматриваемой задачи эти метрики полезны как нижний уровень качества: если детекция неустойчива, последующие шаги также будут деградировать [19].

Для локализации ключевых точек в проекте используются *pose_precision*, *pose_recall*, *pose_mAP* и *РСК*. В рассматриваемой реализации ключевые точки задают центр шкалы и границы основной дуги. Они особенно важны для геометрического пайплайна, потому что даже корректно выделенная стрелка не позволит получить правильное значение, если начало или конец шкалы сдвинуты относительно истинного положения [3, 7].

Для сегментации стрелки применяются как стандартные метрики качества масок, так и пиксельные метрики. mAP для масок показывает, насколько хорошо модель обнаруживает экземпляр стрелки как объект, а IoU , $Dice$, pixel precision и pixel recall описывают совпадение предсказанной области с истинной маской. Для тонких объектов, к которым относится стрелка, это принципиально: небольшое смещение маски может давать заметное падение IoU , а соотношение precision и recall помогает понять, модель скорее дорисовывает лишние пиксели или, наоборот, теряет часть стрелки [22, 21, 20].

Для регрессии показания применяются MAE , $RMSE$, R^2 и $DRR@0.02$. Эти метрики позволяют оценить как среднюю ошибку модели, так и долю практически приемлемых предсказаний [14, 7].

Для полного пайплайна дополнительно важны метрики, которые измеряют не отдельный этап, а итоговое чтение прибора. В проекте используются reading_mae , доля предсказаний в пределах 5% абсолютной ошибки, средняя ошибка ключевых точек, segmentation_iou и средняя ошибка угла стрелки. Такой набор метрик полезен тем, что позволяет связать локальные ошибки моделей с конечной ошибкой считывания.

2.6. Сравнение трех постановок задачи

С теоретической точки зрения в работе сопоставляются три способа решения одной и той же задачи. Первый способ основан на локализации циферблата и ключевых точек; он хорошо объясним, но чувствителен к ошибкам отдельных точек. Второй способ дополняет геометрический контур сегментацией стрелки и тем самым переносит часть сложности из задачи поиска одной точки в задачу выделения целого объекта. Третий способ использует прямую регрессию, то есть пытается сразу отобразить изображение циферблата в число. Он проще по контуру и может давать высокое качество на синтетическом тесте, но хуже объясняет источник ошибки и может сильнее страдать от доменного сдвига [3, 4, 14, 7].

Для промышленного применения важен не только лучший численный результат в лабораторном тесте. Если система используется как вспомогательный инструмент для оператора, ей нужна интерпретируемость: желательно понимать, какой именно этап дал сбой. В этом смысле геометрический пайплайн с сегментацией стрелки может быть предпочтительнее прямой регрессии даже при меньшей точности на ранней стадии разработки. Напротив, если задача ограничена хорошо контролируемой съемкой однотипных приборов, прямая регрессия может оказаться более простой и качественной по итоговой ошибке.

2.7. Вывод по теоретической части

Таким образом, задача считывания показаний аналоговых датчиков требует сочетания локализации, геометрического анализа и численной интерпретации. Наиболее естественно сравнивать не изолированные фрагменты контура, а несколько способов формализации одной задачи: keypoint-based геометрию, геометрию с сегментацией стрелки и прямую регрессию показаний. Именно такое сопоставление и составляет основу практической части работы.

3. Практическая часть

3.1. Общая постановка практической части

Практическая часть посвящена сравнению подходов к считыванию показаний аналоговых датчиков. Базой для экспериментов является синтетический датасет SynthGauge из 9000 изображений с разбиением 7000/1000/1000 и единым набором аннотаций: bounding box, ключевые точки, нормализованное показание и, в расширенной версии контура, семантическая маска стрелки [3, 8, 4, 7, 14, 24].

В практической части рассматриваются четыре связанных блока. Первый проверяет, насколько надежно можно найти сам циферблат и восстановить опорные точки шкалы. Второй добавляет сегментацию стрелки и тем самым переводит задачу определения направления указателя из поиска одной точки в анализ всей маски. Третий описывает алгоритм получения угла стрелки и нормализованного показания на основе найденной геометрии. Четвертый сравнивает этот интерпретируемый контур с прямой регрессией, а также фиксирует первые результаты качественной проверки на реальных изображениях.

Такая структура важна для прикладного вывода. Если смотреть только на итоговую ошибку регрессии, можно получить сильный численный результат, но не понять, почему модель ошиблась на конкретном приборе. Если же оценивать отдельные этапы, то становится видно, где находится узкое место: в обнаружении циферблата, в восстановлении шкалы, в выделении стрелки или в переводе угловой геометрии в число.

3.2. Подготовка данных

Подготовка данных согласована с логикой сравниваемых подходов. Для детекции используются полные изображения: из COCO-разметки берется ограничивающая рамка прибора, после чего она переводится в формат YOLO с нормированными координатами центра, ширины и высоты. Этот этап отвечает только

за вопрос, где на изображении находится прибор.

Для моделей, которые работают с геометрией шкалы, используются crop-изображения циферблата. Crop строится по bounding box прибора, но не точно по границам рамки: вокруг циферблата оставляется небольшой запас. В текущей конфигурации используется $pad_ratio = 0.08$. Это нужно, чтобы после обрезки сохранить контекст вокруг корпуса и не потерять элементы шкалы на краях. Координаты ключевых точек пересчитываются из координат полного изображения в координаты crop, а затем нормируются относительно его ширины и высоты.

Для сегментации стрелки используется семантическая маска, в которой отдельным классом размечена стрелка. Из общей indexed mask выбирается только класс стрелки, после чего применяется тот же crop циферблата. Полученная бинарная маска сохраняется для вычисления пиксельных метрик, а для обучения YOLO-seg дополнительно преобразуется в набор полигонов. Таким образом, один и тот же исходный объект дает несколько представлений: bounding box для детекции, keypoints для шкалы, mask для стрелки и численное значение для регрессии.

Для прямой регрессии формируется отдельный JSONL-индекс. Каждая строка содержит путь к crop-изображению циферблата и целевое значение *reading_normalized*. Это значение лежит в диапазоне $[0, 1]$ и означает относительное положение стрелки между началом и концом основной шкалы. Если в дальнейшем известны реальные значения минимума и максимума шкалы, нормализованное предсказание можно перевести в физическую величину по линейной формуле.

3.3. Эксперимент 1. Двухэтапный пайплайн: детекция и ключевые точки

В интерпретируемом пайплайне детектор сначала находит прибор на полном изображении, после чего модель ключевых точек оценивает центр шкалы и границы основной шкалы. В ранней постановке к ключевым точкам также отно-

сился кончик стрелки, но в текущей версии проекта эта роль перенесена на сегментацию стрелки. Такое разделение делает контур более устойчивым: ключевые точки задают систему координат шкалы, а направление стрелки оценивается по маске указателя. Для локализации прибора используется компактная YOLO-модель, а для ключевых точек — YOLO-pose. Обе модели обучаются на синтетических данных и оцениваются на единой тестовой выборке [19, 25, 3, 4].

На рисунке 3.1 показаны примеры работы двухэтапного пайплайна. Видно, что локализация прибора обычно выполняется уверенно, тогда как качество определения ключевых точек зависит от типа шкалы, контраста и положения стрелки.




Рис. 3.1: Примеры работы двухэтапного пайплайна детекции и локализации ключевых точек

Результаты первого этапа приведены в таблице 3.1.

Таблица 3.1: Результаты детекции на тестовой выборке SynthGauge

Модель	Precision	Recall	mAP@0.5	mAP@0.5:0.95
YOLOv8n	0.9864	0.9630	0.9848	0.7803

Результаты детекции показывают, что на синтетическом датасете задача локализации циферблата решается очень надежно. Это означает, что ограничивающим фактором пайплайна становится уже не поиск прибора, а точность восстановления его геометрии.

Результаты второго этапа, связанного с локализацией ключевых точек, приведены в таблице 3.2.

Таблица 3.2: Результаты локализации ключевых точек на тестовой выборке SynthGauge

Модель	Pose P	Pose R	mAP@0.5	mAP50–95	PCK@0.05	PCK@0.10
YOLO11s-pose	0.9999	1.0000	0.9950	0.6200	0.6048	0.6665

Здесь обозначения $PoseP$ и $PoseR$ соответствуют метрикам *pose_precision* и *pose_recall*.

Ключевой вывод состоит в том, что геометрический этап заметно труднее этапа локализации прибора. Детектор обычно уверенно находит циферблат, но восстановление шкалы требует большей точности: ошибка в положении центра или концов шкалы напрямую меняет систему координат, в которой затем считается угол стрелки. Это хорошо согласуется с результатами других работ, где выделение стрелки и восстановление геометрии шкалы рассматриваются как основная проблема интерпретируемого подхода [15, 2, 7, 23].

3.4. Эксперимент 2. Сегментация стрелки

Следующий этап интерпретируемого пайплайна связан с сегментацией стрелки. Его задача состоит в том, чтобы выделить на сгор-изображении все пиксели указателя. В отличие от *keypoint*-подхода, модель не обязана сразу предсказать единственную точку кончика стрелки. Она строит маску, а уже затем из этой маски вычисляется направление.

В проекте этот этап реализован как обучение YOLO-seg модели на сгор-изображениях циферблата. Исходные *semantic masks* содержат несколько классов, но для данной задачи используется только класс стрелки. После выделения

класса формируется бинарная маска. Далее из нее извлекаются контуры, которые сохраняются в формате YOLO segmentation. Параллельно бинарные маски сохраняются отдельно, потому что они нужны для расчета *IoU*, *Dice* и пиксельных precision/recall.

Смысл такого этапа хорошо виден на уровне ошибок. Если модель сегментации выделяет не только стрелку, но и часть шкалы, то возрастает число ложноположительных пикселей и падает pixel precision. Если, наоборот, модель находит только основание стрелки и теряет ее конец, падает pixel recall, а угол может стать нестабильным. Для итогового считывания второй случай обычно опаснее: если кончик стрелки не попал в маску, восстановленный угол будет смещен к центру и может дать неправильное показание.

В таблице 3.3 показана роль сегментации внутри полного контура.

Таблица 3.3: Роль сегментации стрелки в геометрическом пайплайне

Этап	Вход	Выход
Детекция циферблата	Полное изображение	Bounding box прибора
Ключевые точки	Стор циферблата	Центр, начало и конец шкалы
Сегментация стрелки	Стор циферблата	Бинарная маска стрелки
Геометрический расчет	Ключевые точки и маска	Угол стрелки и нормализованное показание

На текущем этапе сегментация важна не только как способ повысить точность. Она делает пайплайн более диагностируемым. По маске можно визуально понять, что именно модель считает стрелкой. Это особенно полезно при переходе к реальным изображениям, где ошибки часто связаны не с абстрактной неспособностью модели, а с конкретными визуальными факторами: бликом на стекле, темной шкалой, нестандартной формой стрелки или загрязнением циферблата.

3.5. Алгоритм получения угла стрелки и показания

После детекции, keypoints и сегментации требуется перейти от визуальных предсказаний к числу. В полном геометрическом пайплайне используются три опорные точки: центр шкалы $c = (x_c, y_c)$, начало шкалы $s = (x_s, y_s)$ и конец шкалы $e = (x_e, y_e)$. Направление стрелки определяется по маске. Пусть M — множество пикселей, которые модель отнесла к стрелке. Для каждого пикселя $p = (x_p, y_p)$ считается расстояние до центра:

$$\rho(p) = (x_p - x_c)^2 + (y_p - y_c)^2.$$

Кончик стрелки оценивается как средняя координата небольшой доли самых дальних от центра пикселей маски. В текущей реализации берется примерно 1% наиболее удаленных пикселей. Это позволяет не зависеть от одного случайного пикселя на краю маски и делает оценку устойчивее к небольшим дефектам сегментации.

Далее для любой точки p угол относительно центра считается в координатах изображения. Поскольку в изображении ось y направлена вниз, используется не обычная математическая формула угла, а угол по часовой стрелке с нулем сверху:

$$\theta(p) = \left(\frac{180}{\pi} \text{atan2}(x_p - x_c, y_c - y_p) + 360 \right) \bmod 360.$$

По этой формуле вычисляются три угла: $\theta_s = \theta(s)$ для начала шкалы, $\theta_e = \theta(e)$ для конца шкалы и $\theta_n = \theta(n)$ для кончика стрелки. Затем определяется угловой размер основной шкалы:

$$S = (\theta_e - \theta_s) \bmod 360,$$

и прогресс стрелки относительно начала шкалы:

$$P = (\theta_n - \theta_s) \bmod 360.$$

Если стрелка находится внутри дуги шкалы, нормализованное показание получается как

$$\hat{r} = \frac{P}{S}.$$

Значение $\hat{r} = 0$ соответствует началу шкалы, а $\hat{r} = 1$ — ее концу. Если вычисленный угол стрелки оказался чуть вне видимой дуги, пайплайн не переносит его через полный круг, а прижимает к ближайшей границе шкалы. Это важно для устойчивости: небольшая ошибка около начала шкалы не должна превращаться в почти максимальное показание только из-за циклической природы углов.

Такой алгоритм является интерпретируемым. Для каждого предсказания можно отдельно посмотреть `stop`, `keypoints`, маску стрелки, найденный кончик и итоговый угол. Это делает его удобным для анализа ошибок и для будущего промышленного внедрения, где пользователю важно не только получить число, но и понимать, почему система решила именно так.

3.6. Эксперимент 3. Прямая регрессия показания

В регрессионном подходе задача решается напрямую как предсказание нормализованного показания по изображению циферблата. В качестве базовой модели используется ResNet-18. В отличие от геометрического пайплайна, этот подход не восстанавливает геометрию явно, а сразу переводит изображение в числовое значение [8, 14, 7].

На рисунке 3.2 показаны примеры работы регрессионной модели. В большинстве случаев предсказания близки к истинным значениям, однако сам механизм ошибки здесь менее прозрачен.

Для оценки качества используются MAE , $RMSE$, R^2 и $DRR@0.02$. Результаты отражены в таблице 3.4.

Полученные значения показывают, что модель способна достаточно точно предсказывать показание без явной геометрической постобработки. Одновремен-

Таблица 3.4: Результаты прямой регрессии на тестовой выборке SynthGauge

Модель	MAE	$DRR@0.02$	$RMSE$	R^2
ResNet-18	0.0182	0.6970	0.0372	0.9819

но такой подход хуже интерпретируется и потенциально сильнее зависит от доменного сдвига [14, 12, 7].




Рис. 3.2: Примеры предсказаний модели прямой регрессии на изображениях датчиков

3.7. Тест на реальных данных

Отдельная проверка выполнена для реальных изображений с landmark-разметкой. В отличие от синтетического набора, реальные данные не содержат такой же полной semantic mask стрелки, поэтому эксперимент не является полностью симметричным синтетическому тесту. Для реальных изображений используются категории, соответствующие центру прибора, минимуму шкалы, максимуму шкалы, кончику стрелки и самому прибору. Истинное нормализованное показание для такого набора можно получить геометрически: по разметке центра, начала и конца шкалы, а также по разметке кончика стрелки.

Этот тест важен именно как проверка переноса, а не как финальная демон-

страция промышленной готовности. На синтетических изображениях модели видят распределение, близкое к обучающему: похожие материалы, ракурсы, разметку и типы шкал. Реальные фотографии отличаются сильнее. Там появляются неидеальные углы съемки, неравномерное освещение, стеклянные блики, низкое разрешение, частично закрытые циферблаты, фоновые объекты и приборы, которые не совпадают с синтетическими шаблонами.

Качественная проверка показывает, что отдельные элементы пайплайна переносятся на реальные изображения, но пока не идеально. Детекция прибора часто остается наиболее устойчивым этапом: если прибор хорошо виден и занимает заметную часть кадра, модель обычно способна найти область циферблата. Основные проблемы возникают дальше. Keypoints могут смещаться на шкалах с нестандартным расположением делений, а сегментация стрелки может путать стрелку с темными делениями, бликами или декоративными элементами. В результате итоговое показание иногда оказывается правдоподобным, но в других случаях ошибка становится заметной.

Такой результат не следует скрывать: текущий пайплайн пока нельзя считать готовым промышленным решением для произвольных реальных фотографий. Его сильная сторона состоит в том, что он дает понятную структуру ошибки. Если на реальном изображении неверно выделена стрелка, это видно по маске. Если неверно найдены границы шкалы, это видно по keypoints. Это лучше, чем ситуация с прямой регрессией, где модель может дать неверное число без объяснимого промежуточного состояния.

Главный вывод из теста на реальных данных заключается в том, что синтетическое обучение дает полезную стартовую точку, но само по себе не закрывает задачу sim-to-real. Для улучшения качества нужны либо реальные доразмеченные изображения, либо более агрессивная доменная рандомизация, либо адаптация модели на небольшом наборе фотографий с целевого производства. Для малых заводов это все равно может быть практичным сценарием: требуется не полная замена оборудования, а сбор ограниченного набора фотографий уже установлен-

Таблица 3.5: Качественные наблюдения на реальных изображениях

Компонент	Что работает лучше	Основные проблемы
Детекция	Находит крупные и хорошо видимые приборы	Ошибается при частичном перекрытии, сложном фоне и малом размере прибора
Ключевые точки	Устойчива на простых круглых шкалах	Смещается на нестандартных шкалах, при бликах и низком контрасте
Сегментация стрелки	Позволяет визуально проверить направление указателя	Может захватывать деления шкалы или терять тонкий конец стрелки
Итоговое считывание	Иногда дает правдоподобное значение без ручного вмешательства	Пока нестабильно для полностью автономного применения

ных приборов и донастройка модели под конкретные условия съемки.

3.8. Сравнительный анализ результатов

Сопоставление подходов позволяет сделать несколько выводов. Во-первых, локализация самого прибора на синтетических данных уже не является главным ограничением. Во-вторых, внутри интерпретируемого пайплайна узким местом остается восстановление геометрии: нужно одновременно правильно найти центр, границы шкалы и направление стрелки. Сегментация стрелки делает этот этап более содержательным, потому что позволяет использовать всю форму указателя, а не только одну точку.

В-третьих, по имеющимся численным результатам на синтетическом тесте наиболее качественным методом остается прямая регрессия. Значение $MAE = 0.0182$ означает, что средняя ошибка составляет около 1.8% от нормированного диапазона шкалы, а $R^2 = 0.9819$ указывает на сильное соответствие предсказаний истинным значениям. Если оценивать только синтетический benchmark и только конечное число, этот подход выглядит лучшим.

Однако для реального внедрения вывод сложнее. Прямая регрессия является менее прозрачной: если она ошиблась, трудно понять, увидела ли модель неверную стрелку, перепутала шкалу или просто столкнулась с незнакомым визуальным стилем. Интерпретируемый пайплайн с сегментацией пока уступает по зрелости, но лучше подходит для диагностики и постепенного улучшения. По-

этому текущий итог можно сформулировать так: лучшим по численной синтетической метрике является регрессионный подход, а наиболее перспективным для промышленного развития является гибридный геометрический пайплайн с детекцией, keypoints и сегментацией стрелки.

3.9. Ограничения текущей реализации и план доработки

Из полученных результатов можно сформулировать следующие ограничения:

1. Основные численные результаты получены на синтетическом наборе данных; перенос на реальные изображения пока не является стабильным.
2. Интерпретируемый пайплайн чувствителен к ошибкам keypoints и маски стрелки, поскольку итоговое показание вычисляется из геометрии.
3. Реальные изображения часто отличаются от синтетических по освещению, фону, качеству съемки и внешнему виду приборов.
4. Прямая регрессия показывает сильный результат на синтетике, но хуже подходит для анализа причин ошибки.

Исходя из этого, направления дальнейшей доработки звучат так:

1. Расширить набор реальных изображений и добавить разметку, достаточную для проверки полного пайплайна, включая маску стрелки.
2. Улучшить доменную рандомизацию синтетического генератора: добавить больше бликов, загрязнений, неидеальных ракурсов, низкого разрешения и реальных фоновых условий.
3. Сравнить прямую регрессию с полным геометрическим пайплайном не только на синтетике, но и на небольшом наборе реальных приборов [5, 6, 14].

4. Исследовать гибридный подход, в котором геометрический пайплайн дает интерпретируемую оценку, а регрессия используется как дополнительная проверка или корректор.
5. Исследовать возможности облегчения модели и ее дальнейшего промышленного внедрения, включая квантование, использование более компактных архитектур и воспроизводимые MLOps-конвейеры [26, 27, 28, 29].

3.10. Вывод по практической части

Результаты экспериментов показывают, что реализованный пайплайн уже задает хорошую основу для дальнейшей работы. Его сильная сторона состоит в том, что отдельные компоненты задачи не смешиваются в один черный ящик: детекция, keypoints, сегментация стрелки, геометрический расчет и регрессия могут анализироваться отдельно. На текущем синтетическом тесте наиболее качественный итоговый численный результат показывает прямая регрессия. В то же время для реального промышленного применения более перспективным выглядит интерпретируемый контур с сегментацией стрелки, потому что он позволяет видеть источник ошибки и постепенно адаптировать систему под конкретные приборы.

Практический вывод особенно важен для малых производств. Уже сейчас можно рассматривать подобный подход как технологию мягкой цифровизации: не заменять всю измерительную цепочку, а добавить визуальное считывание поверх существующих аналоговых приборов. Полностью автономным решением текущую систему считать рано, особенно на реальных изображениях. Но как исследовательская и инженерная база для дальнейшей адаптации она показывает понятное направление развития: собрать небольшой набор реальных фотографий, донастроить модели под целевой объект, сохранить интерпретируемую геометрию и использовать регрессию как сильный baseline для сравнения.

Список литературы

- [1] J. Schleich и др. «Sensors 4.0: Smart Sensors and Measurement Technology Enable Industry 4.0». В: *Journal of Sensors and Sensor Systems* 7 (2018), с. 359—371. URL: <https://jsss.copernicus.org/articles/7/359/2018/jsss-7-359-2018.pdf> (дата обр. 26.01.2026).
- [2] «Reading Analog Gauges Using OpenCV for Hazardous Area Applications». В: *International Journal of New Technology and Research* (2021). URL: https://www.ijntr.org/download_data/IJNTRSIJUN21009.pdf (дата обр. 26.01.2026).
- [3] B. Howells, J. Charles и R. Cipolla. «Real-Time Analogue Gauge Transcription on Mobile Phone». В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*. 2021, с. 2369—2377.
- [4] M. Reitsma, J. Keller, K. Blomqvist и R. Siegwart. «Under Pressure: Learning-based Analog Gauge Reading in the Wild». В: *2024 IEEE International Conference on Robotics and Automation*. 2024, с. 14—20.
- [5] C.-H. Wang, K.-K. Huang, R.-I. Chang и C.-K. Huang. «Scale-Mark-Based Gauge Reading for Gauge Sensors in Real Environments with Light and Perspective Distortions». В: *Sensors* 22.19 (2022), с. 7490.
- [6] «Coordinates Transformation Method for Pointer Gauge Reading by Machine Vision». В: *Journal of Physics: Conference Series* 2431 (2023). URL: <https://iopscience.iop.org/article/10.1088/1742-6596/2431/1/012019> (дата обр. 26.01.2026).
- [7] «End-to-End Deep Learning for Analog Gauge Reading». В: *Scientific Reports* (2024). URL: <https://www.nature.com/articles/s41598-024-81248-7> (дата обр. 26.01.2026).
- [8] J. Leon-Alcazar, Y. Alnumay, C. Zheng, H. Trigui, S. Patel и B. Ghanem. «Learning to Read Analog Gauges from Synthetic Data». В: *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. 2024.

- [9] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba и P. Abbeel. «Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World». B: *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems*. 2017, с. 23—30.
- [10] D. Horvath, G. Erdos, Z. Istenes, T. Horvath и S. Foldi. «Object Detection Using Sim2Real Domain Randomization for Robotic Applications». B: *IEEE Transactions on Robotics* 39.2 (2023), с. 1225—1243.
- [11] M. Denninger, M. Sundermeyer, D. Winkelbauer, D. Olefir, T. Hodan, Y. Zidan, M. Elbadrawy, M. Knauer, H. Katam и A. Lodhi. «BlenderProc: Reducing the Reality Gap with Photorealistic Rendering». B: *RSS 2020 Workshop on Closing the Reality Gap in Sim2Real Transfer for Robotics*. 2020.
- [12] W. Zhang и др. «Domain Adaptation via Deep Transfer Learning». B: *Proceedings of PMLR*. 2019. URL: <https://proceedings.mlr.press/v97/zhang19i/zhang19i.pdf> (дата обр. 26.01.2026).
- [13] A. Celso и др. *Synthetic Data Generation for Computer Vision Applications*. URL: https://graphics.stanford.edu/courses/cs348n-23-spring/PapersReferenced/CelsoARL_paper.pdf (дата обр. 26.01.2026).
- [14] «End-to-End Intelligent Systems for Visual Measurement». B: *Engineering Applications of Artificial Intelligence* (2024). URL: <https://www.sciencedirect.com/science/article/pii/S0952197624010212> (дата обр. 26.01.2026).
- [15] «Gauge Inspection Using Hough Transforms». B: *Medical Engineering & Physics* (2011). URL: <https://pubmed.ncbi.nlm.nih.gov/21869149/> (дата обр. 26.01.2026).
- [16] *Hough Transform: Theory and Applications*. 2015. URL: <https://arxiv.org/abs/1502.02160> (дата обр. 26.01.2026).

- [17] «Incremental Circle Hough Transform: An Improved Approach». В: *Optik* (2016). URL: <https://d1wqtxts1xzle7.cloudfront.net/95229451/j.ijleo.2016.12.06420221204-1-otufwo-libre.pdf> (дата обр. 26.01.2026).
- [18] М. А. Кудрина. *Использование преобразования Хафа для обнаружения прямых линий и окружностей на изображении*. 2014. URL: <https://cyberleninka.ru/article/n/ispolzovanie-preobrazovaniya-hafa-dlya-obnaruzheniya-pryamyh-linii-i-okruzhnostey-na-izobrazhenii> (дата обр. 26.01.2026).
- [19] *YOLO-Based Object Detection: A Survey*. 2022. URL: <https://arxiv.org/pdf/2208.00773> (дата обр. 26.01.2026).
- [20] О. Ronneberger, P. Fischer и Т. Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. 2015. URL: <https://arxiv.org/pdf/1505.04597> (дата обр. 26.01.2026).
- [21] L.-C. Chen и др. *DeepLab: Semantic Image Segmentation with Deep Convolutional Nets*. 2016. URL: <https://arxiv.org/pdf/1606.00915> (дата обр. 26.01.2026).
- [22] Kaiming He и др. «Mask R-CNN». В: *Proceedings of ICCV*. 2017. URL: https://openaccess.thecvf.com/content_ICCV_2017/papers/He_Mask_R-CNN_ICCV_2017_paper.pdf (дата обр. 26.01.2026).
- [23] «Hybrid YOLOv8 and DeepLab Approach for Gauge Reading». В: *Sensors* (2024). URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11487445/pdf/sensors-24-05288.pdf> (дата обр. 26.01.2026).
- [24] Mileeena. *synthetic-analog-gauges*. Hugging Face dataset repository for SynthGauge. URL: <https://huggingface.co/datasets/Mileeena/synthetic-analog-gauges> (дата обр. 10.04.2026).
- [25] М. Е. Васильев, А. С. Шалимов и О. А. Савина. «Обзор версий YOLO: одноэтапная модель сверточной нейронной сети». В: *Universum: технические науки* 6(135) (2025). URL: <https://7universum.com/ru/tech/archive/item/20293> (дата обр. 26.01.2026).

- [26] *Quantization Techniques for Deep Neural Networks*. 2021. URL: <https://arxiv.org/pdf/2106.08295> (дата обр. 26.01.2026).
- [27] М. Sandler и др. *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. 2017. URL: <https://arxiv.org/pdf/1712.04698> (дата обр. 26.01.2026).
- [28] «Lightweight Deep Learning Model for Industrial Visual Inspection». В: *IEEE Access* (2024). URL: <https://ieeexplore.ieee.org/document/10843390> (дата обр. 26.01.2026).
- [29] *MLOps: Continuous Delivery and Automation Pipelines in Machine Learning*. 2023. URL: <https://arxiv.org/pdf/2308.10908> (дата обр. 26.01.2026).